CAHIER DES CHARGES · PROJET DE SEMESTRE · SQL SERVER (T-SQL)

Filière Big Data Analytics (4e année)

P12
Risque sismique et réponse d'urgence

1. Contexte

Le séisme d'Al Haouz du 8 septembre 2023 a rappelé que la réponse d'urgence dépend de la rapidité à rassembler des informations dispersées : localisation de la secousse, populations exposées, rapports de terrain des équipes, capacités d'hébergement. Une cellule de crise régionale veut un système qui consolide ces sources en quelques heures plutôt qu'en quelques jours.

2. Problématique

> *Comment consolider rapidement des données sismiques, démographiques et de terrain dispersées pour orienter les secours et l'hébergement vers les zones les plus touchées ?*

3. Questions métier auxquelles le système doit répondre

1. Quelle est l'activité sismique au Maroc et dans la région depuis 1970 (fréquence, magnitude, profondeur) ?
2. Quelle population vit à moins de 50 km des épicentres récents de magnitude ≥ 5 ?
3. Quels douars ont le plus fort taux de maisons détruites et des routes coupées ?
4. Les centres d'hébergement sont-ils saturés, et où manque-t-il des places ?
5. Quels besoins prioritaires remontent du terrain, par commune ?

4. Sources de données

Source	Format	Liens d'accès	Contenu
USGS Earthquake Catalog	API REST (GeoJSON, CSV), sans clé	Documentation FDSN · Exemple : `https://earthquake.usgs.gov/fdsnws/event/1/query?format=geojson&starttime=2000-01-01&minlatitude=27&maxlatitude=36&minlongitude=-13&maxlongitude=-1&minmagnitude=4`	Séismes : date, position, magnitude, profondeur
GeoNames	Fichier texte tabulé (ZIP)	Dossier de téléchargement · Fichier `MA.zip` (Maroc) ou `cities1000.zip`	Localités, coordonnées, population
Banque mondiale — Indicators API	API REST (JSON)	Documentation · Exemple : `https://api.worldbank.org/v2/country/MAR/indicator/SP.RUR.TOTL?format=json`	Population rurale

Source	Format	Liens d'accès	Contenu
Kit enseignant P12	CSV ×10, Excel	Dossier `P12_Seismes` du kit	Rapports de terrain (SIMULÉS), centres d'hébergement

5. Exigences par étape du pipeline

Extraction et collecte

Scripts rejouables pour chaque source ; conservation des fichiers et réponses brutes (dossier `raw/AAAA-MM-JJ/`) ; journal de collecte.

Stockage

Zone de staging `stg` fidèle aux sources (colonnes en texte si nécessaire), puis zone nettoyée en 3NF.

Traitement et ETL (règles propres au projet)

- Empiler les 10 rapports de terrain en ajoutant la commune, qui ne figure que dans le nom du fichier
- Normaliser l'état des routes et classer les besoins prioritaires (texte libre) en catégories
- Charger le GeoJSON USGS avec OPENJSON et créer des colonnes de type geography
- Calculer les distances épicentre-localité avec STDistance
- Contrôler capacité $\geq$ personnes hébergées

Modélisation et schéma

Modèle relationnel normalisé (MCD/MLD) pour les données opérationnelles, puis entrepôt en étoile. Proposition de départ (à critiquer et compléter) :

Faits : FAIT_SEISME (date, point, magnitude, profondeur), FAIT_EVALUATION_DOUAR (ménages, détruites, endommagées, besoin), FAIT_HEBERGEMENT, FAIT_EXPOSITION (séisme × localité, distance, population). Dimensions : DIM_DATE, DIM_LIEU (douar, commune, province), DIM_LOCALITE, DIM_BESOIN, DIM_GESTIONNAIRE.

Reporting (Power BI)

Pages attendues :

- Carte des séismes (taille = magnitude)
- Population exposée par séisme
- Carte des dégâts par douar et état des routes
- Saturation des centres d'hébergement

Gestion des accès et sécurité

Rôle	Droits
Cellule de crise	lecture totale
Équipe de terrain	saisit les rapports de sa commune (RLS)
Gestionnaire de centre	met à jour son centre
Partenaire humanitaire	vues agrégées, sans détail nominatif

En situation de crise, la disponibilité compte autant que la confidentialité : décrivez votre stratégie de sauvegarde et de restauration et testez-la (restauration chronométrée).

6. Points d'attention

- Le nom de la commune n'est que dans le nom de fichier
- Les données de terrain sont simulées : ne les présentez pas comme le bilan réel du séisme
- L'API USGS limite le nombre de résultats par requête : découpez par période

7. Pistes bonus

- Index spatial sur les colonnes geography
- Procédure qui, pour un nouveau séisme, liste automatiquement les localités à moins de 100 km

8. Exigences techniques (SQL Server)

- **SGBD** : SQL Server, développement en T-SQL dans SSMS. Trois bases ou trois schémas séparés : `stg` (données brutes chargées telles quelles), `ods` ou `dbo` (données nettoyées, modèle relationnel en 3NF), `dw` (entrepôt en étoile).
- **Collecte** : au moins **4 sources de 3 types différents**, dont au moins **une API** et **le kit de fichiers fourni**. Chaque extraction est rejouable (script versionné) et chaque fichier brut est conservé avec sa date de collecte.
- **ETL en T-SQL** : procédures stockées de chargement (`BULK INSERT`, `OPENROWSET`, `OPENJSON`, fonctions XML), transactions et gestion d'erreurs (`TRY…CATCH`), table de rejets et journal de chargement (date, source, lignes lues, chargées, rejetées). Un outil externe (Python, SSIS, Power Query) est autorisé pour l'extraction d'API, **pas pour les transformations**, qui restent en T-SQL.
- **Qualité** : un rapport de profilage avant/après (valeurs manquantes, doublons, valeurs hors domaine) et des contraintes (`PRIMARY KEY`, `FOREIGN KEY`, `CHECK`, `UNIQUE`, `NOT NULL`).
- **Modélisation** : MCD, MLD, script de création ; schéma en étoile avec au moins 2 tables de faits et une dimension date complète.
- **Performance** : au moins 3 index justifiés, avec plans d'exécution avant/après.
- **Sécurité** : connexions et utilisateurs SQL, rôles de base de données, droits accordés aux rôles et non aux personnes, au moins une stratégie de **Row-Level Security**, du **Dynamic Data Masking** sur les colonnes sensibles, un journal d'audit et une sauvegarde/restauration testée.

- **Versionnement** : un dépôt Git par groupe ; scripts numérotés (`01_create_stg.sql`, `02_load_…sql`…).

9. Exigences de restitution · Big Data Analytics (Power BI)

- **Connexion** à l'entrepôt `dw` en mode Import ou DirectQuery, choix justifié (volume, fraîcheur des données).
- **Modèle sémantique** propre : relations en étoile 1-N à sens unique, table de dates marquée comme telle, colonnes techniques masquées, noms lisibles par un métier.
- **Au moins 10 mesures DAX** documentées (nom, formule, signification), dont au moins une comparaison temporelle (`SAMEPERIODLASTYEAR`, `DATEADD`) et un ratio.
- **4 pages minimum** (celles de la section 5.5), dont une page « qualité des données » alimentée par la table de rejets et le journal de chargement.
- **Interactivité** : segments (filtres), info-bulles et au moins une exploration hiérarchique (drill-down).
- **Sécurité** : un rôle RLS Power BI cohérent avec la Row-Level Security de SQL Server, testé avec « Afficher en tant que ».
- **À rendre** : le fichier `.pbix`, un export PDF des pages et le document des mesures DAX, dans `reporting/`.