PROJET DE SEMESTRE · DOCUMENT COMMUN AUX 13 PROJETS

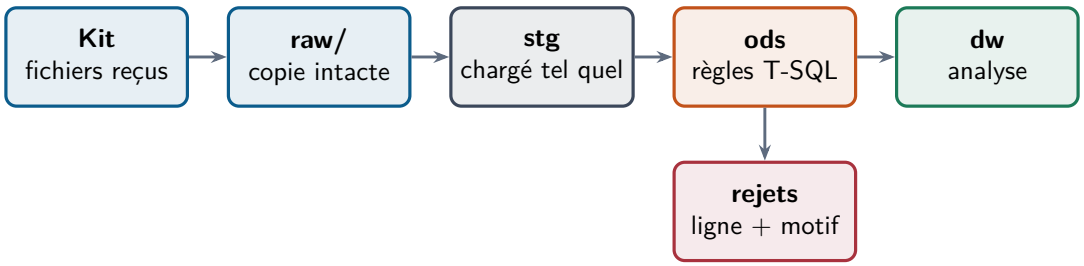
Guide des kits de données

1. Qu'est-ce qu'un kit ?

Chaque projet reçoit un dossier de fichiers dans l'archive `Kits_donnees_13_projets.zip` (dossier `PXX_…`). Ces fichiers jouent le rôle des **données internes du commanditaire** : exports d'hôpitaux, relevés d'enquêteurs, tickets de maintenance, rapports de terrain… Ils complètent les sources publiques (API, Kaggle, open data) listées dans votre cahier des charges.

- Les données sont **simulées** : elles ressemblent à de vraies données, mais ne décrivent aucune personne ni aucun événement réel.
- Elles sont **volontairement imparfaites**, comme en entreprise : plusieurs services, plusieurs formats, plusieurs habitudes de saisie.
- Chaque dossier contient un fichier `LISEZMOI.txt` qui décrit les fichiers.

2. Comment utiliser le kit



1. **Copier** le dossier du kit dans `raw/AAAA-MM-JJ/` de votre dépôt, sans rien modifier.
2. **Explorer** chaque fichier : structure, encodage, séparateur, onglets, types de valeurs. Notez tout ce qui vous surprend.
3. **Charger** chaque fichier dans le schéma `stg` tel quel, colonnes en texte si nécessaire (`BULK INSERT`, `OPENROWSET`, `OPENJSON`).
4. **Profiler** : nombre de lignes, valeurs vides, doublons, valeurs hors domaine, formats différents pour une même information.
5. **Écrire les règles de nettoyage en T-SQL** (procédures stockées) pour passer de `stg` à `ods`. Une ligne impossible à corriger va dans une **table de rejets**, avec son motif.
6. **Relier** les données du kit aux sources publiques (dates, communes, produits, codes) et les charger dans l'entrepôt `dw`.

> **Règle d'or : on ne corrige jamais un fichier à la main.** Pas de modification dans Excel ni dans un éditeur de texte. Toute correction est une règle écrite en T-SQL, rejouable sur une nouvelle livraison du même fichier.