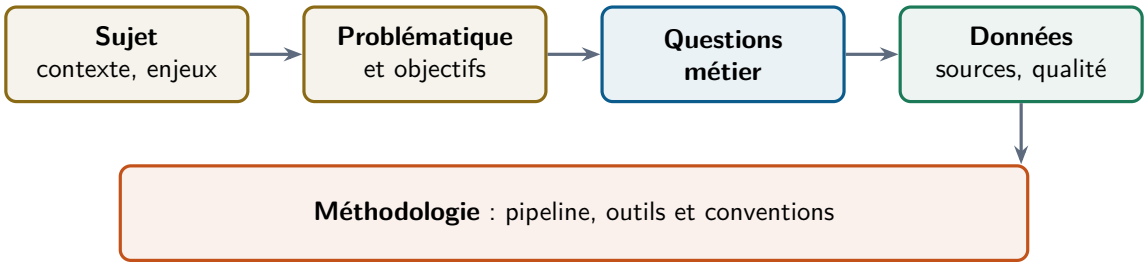
PROJET DE SEMESTRE · DOCUMENT COMMUN AUX 13 PROJETS

Big Data Analytics Full-Stack

Livrable J1
Note de cadrage : le sujet et les données

1. À quoi sert ce livrable

La note de cadrage prouve que le groupe a compris le problème **avant** d'écrire la moindre ligne de SQL. Elle répond à quatre questions : quel problème réel traitons-nous, quelles questions le système devra-t-il trancher, avec quelles données, et comment allons-nous travailler.



2. Plan imposé

Respectez cet ordre et ces titres.

N°	Section	Contenu
—	Page de garde	projet, filière, membres, lien Git
1	Présentation du sujet	contexte, commanditaire, utilisateurs, enjeux
2	Problématique et objectifs	problématique reformulée, périmètre, objectifs mesurables
3	Questions métier	questions traduites en indicateurs et en données
4	Les données	inventaire, description, choix, qualité, contraintes
5	Méthodologie	pipeline, outils et conventions
6	Références	sources citées, licences
—	Annexes	échantillons, réponse d'API brute, captures

3. Le sujet, la problématique et les objectifs (sections 1 et 2)

3.1 Présentation du sujet

Expliquez le problème réel avec vos mots, sans recopier le cahier des charges. Questions guides :

- Qui est le commanditaire, et qui utilisera le système au quotidien ?
- Quelle décision ce système aidera-t-il à prendre ? Que se passe-t-il aujourd'hui sans lui ?
- Pourquoi ce problème compte-t-il dans la vie réelle (santé, argent, sécurité, environnement) ?

3.2 Problématique, périmètre et objectifs

- **Problématique** : une seule phrase interrogative, reformulée par le groupe.
- **Périmètre** : ce qui est inclus et exclu (période, zone géographique, population, sources).
- **Objectif général** : une phrase. **Objectifs spécifiques** : 3 à 5, chacun commençant par un verbe d'action et associé à un indicateur vérifiable.

Exemple (P10, prix alimentaires).

Objectif spécifique	Indicateur de réussite
Normaliser tous les relevés de prix au kilo ou au litre	100 % des relevés valides convertis ; rejets tracés avec leur motif
Comparer le panier des souks à l'inflation officielle	indice base 100 calculé chaque mois depuis janvier 2023

4. Les questions métier (section 3)

Reprenez les 5 questions de votre cahier des charges et **ajoutez-en au moins une**. Pour chacune, montrez comment elle deviendra un chiffre.

N°	Question	Indicateur / calcul	Données nécessaires
Q1	Quels marchés sont les moins chers pour un panier type ?	somme des prix au kilo des 8 produits du panier	relevés enquêteurs, nomenclature produits

Exemple tiré de P10.

5. Les données (section 4)

5.1 Inventaire des sources

Un tableau unique, une ligne par source, kit de l'enseignant compris. Rappel : au moins **4 sources de 3 types différents**, dont **une API**.

Source	Type	Format	Accès (lien, clé)	Licence	Période	Volume	Mise à jour
Taux BCE	fichier ouvert	XML	lien direct, sans clé	libre, citer la BCE	1999 → auj.	environ 7 000 jours	quotidienne

5.2 Description de chaque source

Pour chaque source, une courte fiche :

- **Rôle** : à quelles questions métier elle répond (Q1, Q3…).
- **Structure** : fichiers, onglets, tables ou routes d'API ; nombre de lignes et de colonnes observé.

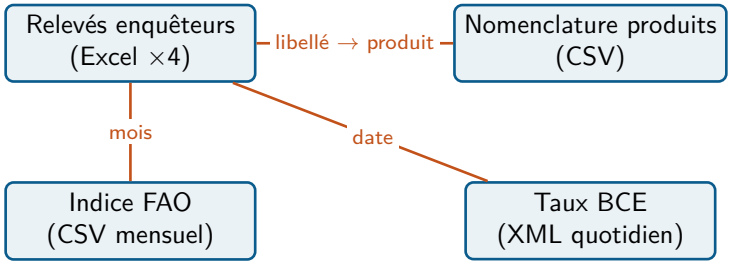
- **Dictionnaire préliminaire** des champs utiles : nom, type, unité, exemple de valeur, signification.
- **Clés de liaison** : le champ qui permettra de la relier aux autres sources (date, code commune, identifiant produit, nom normalisé…).

Extrait de dictionnaire (P10, relevés des enquêteurs).

Champ	Type observé	Unité	Exemple	Signification
`semaine`	texte	—	02/01/2023	lundi de la semaine du relevé (2 formats)
`produit`	texte libre	—	tmatem	libellé saisi ; à relier à la nomenclature
`prix_dh`	texte	DH / unité	131,50	prix pour l'unité indiquée (kg, sac 25 kg…)

5.3 Choix et justification

- Pourquoi ces sources ? Les sources envisagées puis écartées, et la raison (accès, licence, qualité, couverture).
- Un **schéma de liaison** montrant comment les sources se relient entre elles (exemple ci-dessous).



5.4 Premier diagnostic de qualité

Sur l'échantillon téléchargé, relevez les défauts réellement observés et le traitement envisagé. Visez au moins **5 anomalies** documentées.

Source	Anomalie observée	Exemple	Traitement envisagé
Relevés enquêteurs	même produit, libellés différents	tmatem / Tomates	table de correspondance libellé → produit
Relevés enquêteurs	décimale virgule en texte	5,97	conversion en `DECIMAL` en T-SQL

5.5 Données sensibles et contraintes

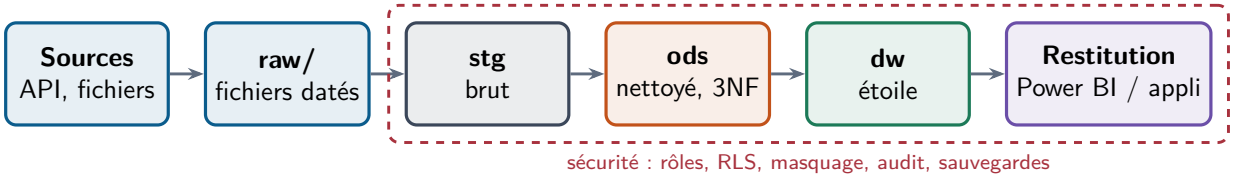
- Données personnelles ou de santé présentes ? Lesquelles, et quelle protection prévue (masquage, agrégation, chiffrement) ?
- Cadre légal : loi marocaine 09-08 (CNDP), et RGPD si les données concernent des personnes en Europe.

- Licences et obligations de citation ; limites d'appels des API ; stockage des clés (fichier `.env` hors du dépôt).

6. La méthodologie (section 5)

6.1 Pipeline envisagé

Dessinez **votre** pipeline, en nommant l'outil de chaque étape. Le schéma ci-dessous est le cadre commun à respecter.



6.2 Outils et conventions

Version de SQL Server et de SSMS, outil d'extraction des API (Python, PowerShell…), conventions de nommage (schémas `stg`, `ods`, `dw` ; tables en minuscules ; procédures préfixées `usp_`), organisation du dépôt Git.

7. Références et annexes (section 6)

Citez chaque source (organisme, titre, lien, date de consultation, licence). En annexe : un extrait de chaque fichier, une réponse d'API brute (tronquée), et toute capture utile.