UEMF
الجامعة الأورومتوسطية بفاس
ⵜⴰⵙⴷⴰⵡⵜ ⵜⴰⵎⵓⵔⵓⵎⵉⵜⵉⵜ ⵏ ⴼⴰⵙ
EUROMED UNIVERSITY OF FES

EIDIA
École d'Ingénierie Digitale et d'Intelligence Artificielle

**UNIVERSITÉ EUROMED DE FÈS**

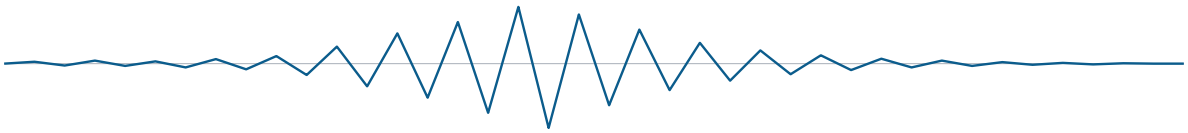
EIDIA : Big Data Analytics

# LIVRABLE J1

Note de cadrage : le sujet et les données

# Risque sismique et réponse d'urgence

Séisme d'Al Haouz : Maroc



| | |
|---|---|
| **Projet** | P12 : Projet de semestre 2026–2027 |
| **Cours** | SGBD : Big Data Analytics |
| **Groupe** | Groupe P12 |
| **Membres** | Douaa Haichar, Aya Zzouitine et Salma Dakak |
| **Dépôt Git** | https://github.com/codingariba |

Année universitaire 2026–2027

## 1. Présentation du sujet

**Contexte.** Le 8 septembre 2023, un séisme majeur a frappé la région du Haut-Atlas au Maroc, notamment la province d'Al Haouz. La réponse d'urgence nécessite de rapprocher plusieurs catégories d'informations : événements sismiques, localités, rapports de terrain et capacités des centres d'hébergement. Ces informations sont fournies dans des formats et selon des structures différents.

**Commanditaire et utilisateurs.** Dans le cadre pédagogique du projet, le système est conçu pour répondre aux besoins d'une cellule régionale de coordination de crise (commanditaire cible, et non client réel confirmé). Les utilisateurs visés sont les coordinateurs de terrain, les responsables de centres d'hébergement et les partenaires humanitaires autorisés. Les vues destinées aux partenaires devront présenter des données agrégées.

**Décisions à éclairer.** Le système doit aider à repérer les communes et douars présentant des dommages importants, à identifier les difficultés d'accès, à suivre la saturation des centres et à répartir les besoins prioritaires. Sans consolidation, les décideurs risquent de travailler avec des fichiers dispersés, des libellés différents et des indicateurs difficiles à comparer.

**Enjeu.** L'objectif est de fournir une base cohérente et traçable pour l'analyse et la priorisation. Les rapports du kit enseignant sont des données simulées à des fins pédagogiques : ils ne doivent pas être présentés comme des statistiques officielles sur les victimes ou les dégâts réels.

## 2. Problématique et objectifs

### 2.1 Problématique

*Comment consolider des données sismiques, démographiques et de terrain hétérogènes afin d'identifier les communes les plus touchées et d'éclairer l'orientation des secours et des capacités d'hébergement ?*

### 2.2 Périmètre

| | Inclus | Exclu |
|---|---|---|
| Période | Période USGS étudiée : 2000–2026 ; rapports pédagogiques datés de septembre 2023 ; séries World Bank 1960–2025. | Suivi opérationnel en temps réel pendant une catastrophe et suivi de la reconstruction à long terme. |
| Zone | Emprise géographique de la requête USGS (latitude 27 à 36 ; longitude -13 à -1), localités GeoNames correspondantes et dix communes présentes dans le kit. | Généralisation à toutes les provinces du Maroc ; analyse individuelle des bâtiments ou des victimes. |
| Objets | Événements sismiques, localités, ménages et dommages agrégés dans les rapports, centres d'hébergement et indicateurs démographiques nationaux. | Données nominatives, dossiers médicaux, indemnisations individuelles et données détaillées de chaque bâtiment. |

### 2.3 Objectifs

**Objectif général :** concevoir un entrepôt de données fiable, sécurisé et traçable permettant d'analyser les événements sismiques, les dommages de terrain et la situation des centres d'hébergement, puis de restituer les indicateurs dans Power BI.

| N° | Objectif spécifique | Indicateur vérifiable |
|---|---|---|
| O1 | Collecter et conserver les quatre origines de données (kit, USGS, GeoNames et Banque mondiale) dans leur format brut, avec des extractions rejouables et datées. | Quatre origines et trois familles de formats au minimum ; fichiers bruts datés et journal de collecte prévus. |
| O2 | Charger et normaliser les rapports de terrain et les centres d'hébergement en T-SQL. | 179 lignes de rapports et 40 centres à rapprocher ; lignes lues = chargées + rejetées, avec motifs traçables. |
| O3 | Analyser l'activité sismique et la proximité des localités par rapport aux événements significatifs. | 331 événements dans l'extraction USGS 2000–2026 ; indicateurs de fréquence, magnitude et profondeur à calculer sur ce périmètre. |
| O4 | Mesurer les dommages déclarés, l'accessibilité et la saturation des centres par commune. | Indicateurs calculés à partir des 179 rapports et des 40 centres ; dépassements de capacité identifiés. |
| O5 | Mettre en place une architecture sécurisée et contrôlable. | Rôles SQL, RLS, masquage, audit et test de sauvegarde/restauration prévus et documentés. |

## 3. Questions métier

Les cinq premières questions reprennent les cinq questions métier du cahier des charges ; la sixième est ajoutée. Les indicateurs ci-dessous sont des calculs prévus, et non des résultats déjà produits par un entrepôt. Les indicateurs seront calculés à partir des sources décrites ci-dessous.

| N° | Question | Indicateur / calcul envisagé | Données nécessaires |
|---|---|---|---|
| Q1 | Quelle est l'activité sismique au Maroc et dans la région entre 2000 et 2026 (fréquence, magnitude, profondeur) ? | Nombre d'événements par année ; répartition par classes de magnitude ; magnitude moyenne/maximale et profondeur moyenne/maximale. L'analyse porte sur les événements de magnitude supérieure ou égale à 4, conformément au filtre de l'extraction disponible. | USGS : date, magnitude, profondeur et coordonnées ; requêtes découpées par périodes pour respecter les limites de résultats. |
| Q2 | Quelle population vit à moins de 50 km des épicentres récents (depuis le 8 septembre 2023) de magnitude supérieure ou égale à 5 ? | Pour chaque événement retenu : somme des populations GeoNames renseignées des localités situées à 50 km ou moins ; nombre de localités prises en compte et nombre de localités sans population renseignée. Il s'agit d'une estimation partielle, pas d'un décompte exhaustif de la population exposée. | USGS (événements M≥5) et GeoNames (coordonnées et population). STDistance calculera les distances ; les populations manquantes seront signalées, jamais remplacées arbitrairement. |
| Q3 | Quels douars ont le plus fort taux de maisons détruites et des routes coupées ? | Par douar : maisons détruites / ménages × 100 ; état de route normalisé ; classement des douars selon le taux de destruction et signalement des routes coupées. Agrégation possible par commune en complément. | Rapports CSV : douar, ménages, maisons détruites, état de la route ; commune ajoutée à partir du nom du fichier. Les résultats sont des déclarations simulées du kit. |

| N° | Question | Indicateur / calcul envisagé | Données nécessaires |
|---|---|---|---|
| Q4 | Les centres d'hébergement sont-ils saturés, et où manque-t-il des places ? | Taux d'occupation = personnes hébergées / capacité × 100 ; places manquantes = max(0, personnes hébergées - capacité) ; places disponibles = max(0, capacité - personnes hébergées), par centre et par commune. | Excel des centres : capacité, personnes hébergées, centre, commune et gestionnaire. |
| Q5 | Quels besoins prioritaires sont les plus souvent déclarés dans chaque commune ? | Nombre et proportion de rapports par catégorie de besoin, après normalisation contrôlée des libellés. | Rapports CSV : besoin prioritaire et commune. |
| Q6 (ajout) | Quelles communes cumulent les besoins prioritaires les plus fréquents et une forte pression sur l'hébergement ? | Indice de synthèse expérimental combinant la fréquence des besoins prioritaires normalisés et le taux de saturation des centres ; formule, normalisation et pondérations à valider avec l'enseignant. Cet indice ne remplace pas l'analyse des douars de Q3. | Rapports CSV et classeur des centres ; agrégation par commune normalisée. |

## 4. Les données

### 4.1 Inventaire des sources

Le projet satisfait l'exigence de diversité des sources avec des fichiers CSV, un classeur Excel, un jeu géographique téléchargeable et des API. Les quatre origines de données sont le kit enseignant, USGS, GeoNames et la Banque mondiale. Elles sont détaillées en cinq lignes car le kit contient deux fichiers/formats. Les familles de formats comprennent les fichiers tabulaires (CSV/XLSX/TXT) et les API REST (GeoJSON/JSON) ; le téléchargement GeoNames est un export de fichier compressé.

| Source | Type | Format | Accès / référence | Licence / conditions | Période | Volume observé | Mise à jour |
|---|---|---|---|---|---|---|---|
| Rapports terrain du kit enseignant | Fichiers locaux | CSV | 10 fichiers dans le kit fourni | Conditions non précisées ; usage pédagogique | Visites de septembre 2023 | 10 fichiers ; 179 lignes ; 8 colonnes | Statique |
| Centres d'hébergement du kit | Tableur local | XLSX | centres_hebergement.xlsx | Conditions non précisées ; usage pédagogique | Jeu pédagogique | 1 feuille ; 40 lignes ; 5 colonnes | Statique |
| USGS Earthquake Catalog | API REST | GeoJSON | https://earthquake.usgs.gov/fdsnws/event/1/ | Données USGS généralement dans le domaine public américain ; attribution recommandée | 2000–2026 | 331 événements dans la réponse conservée | Interrogeable ; extraction datée |
| GeoNames : Maroc | Fichier géographique | TXT tabulé | https://download.geonames.org/export/dump/MA.zip | CC BY 4.0 ; attribution GeoNames | Base géographique ; dates de modification par lieu | 153 872 lignes ; 19 colonnes | Export téléchargeable |
| World Bank : Rural population | API REST | JSON | https://api.worldbank.org/v2/country/MAR/indicator/SP.RUR.TOTL?format=json&per_page=100 | CC BY 4.0, sous réserve des métadonnées propres à l'indicateur | 1960–2025 | 66 observations | API ; extraction datée |

### 4.2 Description des sources et dictionnaire préliminaire

**Source 1 : Rapports de terrain CSV.** Les dix fichiers représentent chacun une commune. Ils comportent huit champs : `douar`, `menages`, `maisons_detruites`, `maisons_endommagees`, `etat_route`, `acces`, `besoin_prioritaire` et `date_visite`. Les volumes vérifiés par fichier sont : Adassil 8 lignes ; Amizmiz 8 ; Anougal 25 ; Asni 20 ; Ighil 15 ; Imi NTala 23 ; Moulay Brahim 25 ; Ouirgane 21 ; Talat NYaaqoub 17 ; Tizi NTest 17, soit 179 lignes. La commune est déduite du nom du fichier ; la clé de rapprochement envisagée est le couple (commune normalisée, douar), et non le nom du douar seul.

| Champ | Type observé | Exemple de valeur | Signification |
|---|---|---|---|
| `douar` | Texte | Nom de douar du fichier | Localité déclarée dans le rapport. |
| `menages` | Entier | Valeur numérique | Nombre de ménages recensés. |
| `maisons_detruites` | Entier | Valeur numérique | Nombre de maisons détruites déclaré. |
| `maisons_endommagees` | Entier | Valeur numérique | Nombre de maisons endommagées déclaré. |
| `etat_route` | Texte catégoriel | `coupée`, `praticable` | État déclaré de la route. |
| `acces` | Texte catégoriel | `oui`, `non`, `partiel` | Accessibilité déclarée. |
| `besoin_prioritaire` | Texte | `Eau`, `Soins` | Besoin prioritaire déclaré. |
| `date_visite` | Date sous forme texte | `2023-09-23` | Date de visite, présente sous deux formats. |

**Profil global des rapports.** Les 179 lignes totalisent 16 397 ménages, 8 510 maisons détruites et 3 937 maisons endommagées. Aucun champ vide n'a été relevé dans les contrôles effectués ; aucune ligne entièrement dupliquée n'a été détectée. Les noms de douars représentent 87 valeurs distinctes, mais 179 couples (commune, douar) distincts : le nom du douar seul ne constitue donc pas une clé suffisante.

**Source 2 : Centres d'hébergement XLSX.** Le classeur comporte une feuille et cinq colonnes : `centre`, `commune`, `capacite`, `personnes_hebergees`, `gestionnaire`. Il contient 40 centres. Les capacités totalisent 15 652 places et les personnes hébergées 16 590, soit un taux global d'occupation de 105,99 %. Vingt centres sur quarante dépassent leur capacité. Ce dépassement est un signal opérationnel à analyser, pas une anomalie à corriger automatiquement. Les gestionnaires recensés sont FAR (12 centres), Croissant-Rouge (12), Commune (9) et ONG locale (7). La clé de rapprochement avec les rapports est la commune après normalisation.

| Champ | Type observé | Exemple | Signification |
|---|---|---|---|
| `centre` | Texte | Nom du centre | Identifiant/libellé du centre. |
| `commune` | Texte | `Amizmiz` | Commune de rattachement. |
| `capacite` | Numérique entier | Valeur entière | Capacité théorique en personnes. |
| `personnes_hebergees` | Numérique entier | Valeur entière | Nombre de personnes hébergées. |
| `gestionnaire` | Texte catégoriel | `Commune` | Organisme gestionnaire déclaré. |

**Source 3 : USGS.** La réponse GeoJSON conservée correspond au périmètre d'étude retenu, de 2000 à 2026. Elle correspond à la requête suivante : https://earthquake.usgs.gov/fdsnws/event/1/query?format=geojson&starttime=2000-01-01&minlatitude=27&maxlatitude=36&minlongitude=-13&maxlongitude=-1&minmagnitude=4. Elle contient 331 événements. Les champs exploités sont l'identifiant, la magnitude, la date/heure, la profondeur et les coordonnées (longitude, latitude). Les contrôles effectués sur ce fichier provisoire ont relevé zéro valeur manquante dans les champs sélectionnés, zéro identifiant dupliqué, une magnitude minimale de 4,0 et maximale de 6,8, et aucune coordonnée hors

des bornes géographiques valides. La période observée va du 7 mars 2000 au 3 août 2026. Ces contrôles portent sur la cohérence technique des champs, et non sur une validation scientifique des événements.

**Source 4 : GeoNames.** Le fichier `MA.txt` extrait de `MA.zip` est un fichier tabulé de 19 colonnes et 153 872 lignes. Les champs utiles incluent `geonameid`, `name`, `asciiname`, `latitude`, `longitude`, `feature_class`, `feature_code`, `country_code`, `population` et `modification_date`. La classe `P` désigne les lieux habités : 46 946 enregistrements de la base complète appartiennent à cette classe, dont 406 avec une population strictement positive. Dans l'emprise géographique utilisée pour le projet, 153 791 lignes sont conservées ; les chiffres de profilage doivent toujours préciser s'ils concernent le fichier complet ou cette sélection spatiale. La clé technique est `geonameid` ; la liaison avec USGS est spatiale, à partir des coordonnées, et non par nom de lieu.

**Source 5 : World Bank.** L'indicateur `SP.RUR.TOTL` (Rural population) pour le Maroc fournit 66 observations annuelles de 1960 à 2025. Il s'agit d'une donnée nationale de contexte ; elle ne doit pas être jointe directement aux communes ni utilisée comme population locale. La clé temporelle est l'année.

### 4.3 Choix, justification et relations entre sources

Les sources sont retenues car elles répondent à des besoins complémentaires : les rapports et le classeur décrivent les dommages déclarés et l'hébergement ; USGS fournit le contexte sismique ; GeoNames apporte des localités géolocalisées ; World Bank fournit un indicateur démographique national de contexte. Les fichiers du kit sont simulés et leur licence de redistribution n'est pas explicitement précisée : ils sont utilisés dans le cadre pédagogique et ne sont pas présentés comme données officielles.

**Sources envisagées puis non retenues dans le périmètre actuel.** OpenStreetMap/Overpass et HCP/RGPH figuraient dans une première ébauche, mais n'ont pas été téléchargés et profilés dans le jeu de données finalement vérifié ; ils sont donc retirés de l'inventaire et des calculs annoncés. Des images satellites commerciales ont également été écartées, car elles nécessiteraient des données raster, des moyens de traitement et des conditions d'accès/licence dépassant le périmètre du J1. Aucun résultat ne sera attribué à ces sources.

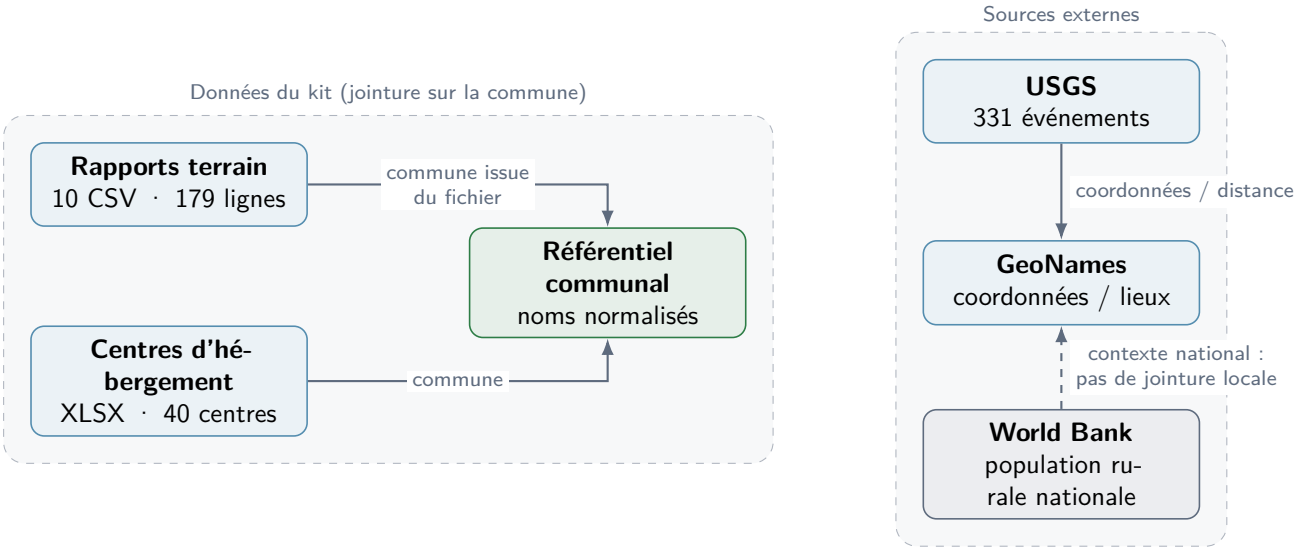



Fig. 1 : Relations prévues entre les sources. Le lien rapports–centres repose sur la commune normalisée ; le lien USGS–GeoNames est spatial ; la série World Bank reste un contexte national (trait pointillé).

**Limite importante de liaison.** Les CSV ne contiennent pas de coordonnées des douars. Il n'est donc pas possible, avec les données actuelles, de calculer une distance fiable entre chaque douar et un épicentre,

ni de relier automatiquement chaque douar à un enregistrement GeoNames. L'analyse spatiale est limitée aux localités géoréférencées de GeoNames et aux événements USGS. La série World Bank reste nationale.

### 4.4 Premier diagnostic de qualité

Les anomalies ci-dessous ont été observées lors du profilage. Les fichiers bruts restent inchangés ; les corrections seront réalisées dans le processus ETL T-SQL ou dans les règles de préparation autorisées, avec traçabilité.

| Source / champ | Anomalie observée | Exemple / mesure | Traitement envisagé |
|---|---|---|---|
| CSV : commune | Variantes d'apostrophes dans les noms de communes | Imi NTala / Imi N'Tala ; Talat NYaaqoub / Talat N'Yaaqoub ; Tizi NTest / Tizi N'Test | Créer une valeur normalisée en ETL ; conserver le libellé source. |
| CSV : date_visite | Deux formats de date coexistent | 87 dates au format AAAA-MM-JJ et 92 au format JJ/MM/AAAA | Parser explicitement les deux formats et convertir vers le type SQL DATE ; rejeter les dates non interprétables. |
| CSV : etat_route | Casse et accents non homogènes | Valeurs observées : `coupée`, `Coupee` et variante d'encodage observée à l'inspection | Normaliser espaces, casse et accents via table de correspondance contrôlée ; conserver la valeur d'origine. |
| CSV : etat_route | Valeur inconnue codée par un symbole | `?` : 39 lignes | Convertir en valeur inconnue/NULL dans la couche nettoyée, sans imputation automatique ; tracer la règle. |
| CSV : route / accès | Combinaisons à examiner | 13 lignes indiquent route praticable et accès non ; 23 indiquent route coupée et accès oui | Ne pas corriger automatiquement ; conserver et signaler pour validation métier. |
| CSV : besoin_prioritaire | Libellés proches mais non identiques | `Tentes` et `tentes / couvertures` | Normaliser la casse ; ne fusionner les catégories qu'après validation métier. |
| Excel : occupation | Capacité dépassée dans plusieurs centres | 20 centres sur 40 ont plus de personnes hébergées que leur capacité | Conserver les valeurs ; créer un indicateur de dépassement et une alerte métier. |
| GeoNames : population | Population absente ou nulle pour la plupart des lieux habités | 406 lieux de classe P sur 46 946 ont une population $> 0$ | Ne pas assimiler une population nulle à une absence d'habitants ; documenter la couverture limitée et éviter les estimations locales non justifiées. |

**Contrôles complémentaires positifs.** Les rapports CSV ne présentent aucune valeur vide ni ligne entièrement dupliquée dans le profilage réalisé. Pour le classeur des centres, les cinq colonnes ne présentent pas de valeur manquante et aucune ligne entièrement dupliquée n'a été détectée ; les champs de capacité et de personnes hébergées ne contiennent pas de valeur négative ou non numérique. Pour USGS, les champs sélectionnés ne présentent aucune valeur manquante et les identifiants sont uniques. Pour GeoNames, les identifiants sont uniques et les coordonnées respectent les bornes valides. Pour World Bank, les 66 années sont distinctes et aucune valeur manquante ou négative n'a été relevée.

### 4.5 Données sensibles et contraintes

- **Nature des données.** Le kit contient des données agrégées par douar ou par centre (ménages, maisons, capacité et personnes hébergées), sans nom de victime ni identifiant personnel dans les fichiers examinés. Ces données peuvent néanmoins révéler des vulnérabilités opérationnelles ; leur diffusion doit donc être maîtrisée.

- **Protection.** Le projet prévoit des comptes et rôles SQL, des droits accordés aux rôles plutôt qu'aux personnes, une stratégie de Row-Level Security, le masquage dynamique des éventuelles colonnes sensibles, un audit et des vues agrégées pour les partenaires. Les sauvegardes et une restauration de test seront documentées.
- **Cadre légal.** La loi marocaine 09-08 et les formalités applicables auprès de la CNDP seront prises en compte si des données personnelles sont introduites. Le RGPD sera examiné si le traitement entre dans son champ territorial ou matériel. Le présent projet ne prétend pas établir à lui seul une conformité juridique.
- **Licences et attribution.** Les conditions du kit enseignant ne précisent pas de licence de redistribution ; son usage est limité au cadre pédagogique. GeoNames est diffusé sous CC BY 4.0 avec attribution. Les données World Bank sont généralement sous CC BY 4.0, sous réserve des mentions propres aux indicateurs. Les données USGS sont généralement dans le domaine public américain ; la source doit être créditée.
- **API et secrets.** Les extractions seront limitées aux besoins du projet, conservées localement avec leur date et leur URL de requête. Aucun secret ou jeton éventuel ne sera commité dans Git ; les fichiers de configuration sensibles seront exclus du dépôt.

## 5. Méthodologie

### 5.1 Pipeline envisagé

L'architecture cible respecte les couches demandées : données brutes conservées, zone de staging, modèle relationnel nettoyé en troisième forme normale, entrepôt en étoile puis restitution. Les transformations et contrôles de données seront réalisés en T-SQL ; Python sera utilisé uniquement pour l'extraction des API et la sauvegarde des réponses brutes.

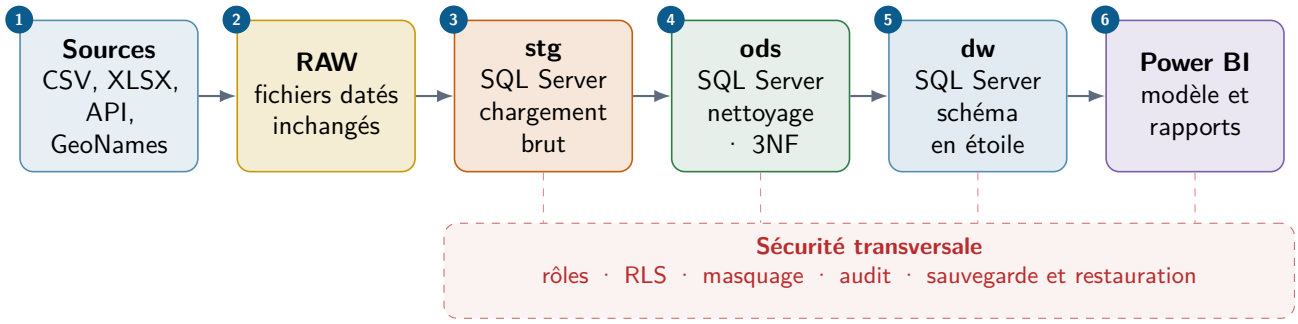



Fig. 2 : Architecture cible du projet, conforme aux couches demandées dans le cahier des charges.

- **Collecte et RAW.** Les fichiers du kit sont conservés sans modification. Python télécharge les API USGS et World Bank ; le fichier GeoNames est conservé dans sa version téléchargée. Chaque extraction est rejouable par un script versionné et chaque fichier brut est associé à une date de collecte.
- **RAW vers stg.** Chargement des données brutes dans SQL Server. Les fichiers CSV/XLSX et GeoJSON/JSON seront importés avec les mécanismes adaptés (par exemple BULK INSERT, OPENROWSET ou OPENJSON selon le format). Les données de staging conservent les valeurs sources, si nécessaire en texte, ainsi que les informations de provenance. Le chargement GeoJSON USGS utilisera OPENJSON ; les coordonnées seront converties en geography pour les calculs STDistance. Les rapports CSV seront empilés en ajoutant la commune issue du nom de fichier. Les états de route et besoins seront normalisés par tables de correspondance validées.

- **stg vers ods.** Les traitements T-SQL assurent le typage, la normalisation des communes, dates et catégories, les contrôles de domaine et les relations du modèle 3NF. Les lignes techniquement non conformes sont enregistrées dans une table de rejets avec leur motif. Le contrôle capacité $\geq$ personnes hébergées sera matérialisé comme règle métier : les dépassements observés seront conservés et signalés comme saturation, et non supprimés comme erreurs de chargement. Les procédures utiliseront transactions et TRY…CATCH ; un journal enregistrera date, source, lignes lues, chargées et rejetées.
- **ods vers dw.** Construction d'un schéma en étoile comprenant au moins deux tables de faits et une dimension date complète. Le modèle en étoile devra comporter au moins deux faits, par exemple `FAIT_SEISME` et `FAIT_EVALUATION_DOUAR`, et pourra être complété par `FAIT_HEBERGEMENT` et `FAIT_EXPOSITION` si les grains et clés sont validés. `DIM_DATE` sera complète et marquée comme table de dates dans Power BI ; les dimensions de lieu, localité, besoin et gestionnaire seront retenues selon les relations réellement disponibles. Le grain de chaque fait sera documenté pour éviter les doubles comptages.
- **Restitution.** Power BI se connectera à la couche `dw`. Le mode Import ou DirectQuery sera choisi et justifié selon le volume et la fraîcheur attendue. Le rapport comprendra les quatre pages métier exigées (carte des séismes, population exposée, dégâts/routes, saturation des hébergements) ainsi qu'une cinquième page consacrée à la qualité des données, alimentée par la table de rejets et le journal de chargement.

### 5.2 Modélisation, performance et sécurité prévues

Le modèle opérationnel sera décrit par un MCD puis un MLD normalisé en 3NF dans `ods`. Le schéma décisionnel `dw` sera un schéma en étoile avec au moins deux tables de faits. La proposition du cahier des charges sera affinée en définissant le grain de chaque fait : un événement par ligne dans `FAIT_SEISME` ; une évaluation de douar par date de visite dans `FAIT_EVALUATION_DOUAR` ; les hébergements et expositions seront modélisés séparément si les clés et grains permettent d'éviter les multiplications de lignes. Les dimensions comprendront au minimum une dimension date complète et les dimensions de lieu/localité nécessaires aux analyses.

Les performances seront évaluées avec au moins trois index justifiés, notamment sur les clés de jointure et les colonnes spatiales si le volume le justifie ; les plans d'exécution seront comparés avant/après. La sécurité prévoira des utilisateurs et rôles SQL, des droits accordés aux rôles, une RLS pour limiter les rapports de terrain à leur commune, du Dynamic Data Masking sur les éventuelles colonnes sensibles, un journal d'audit et un test chronométré de restauration d'une sauvegarde. Ces éléments sont des travaux à réaliser et à tester pendant le projet, pas des fonctionnalités déjà déployées.

### 5.3 Outils et conventions

| Élément | Choix retenu ou prévu |
|---|---|
| SGBD | Microsoft SQL Server 2019 Developer Edition (64-bit), version produit 15.0.2000.5, sur Windows 10 Pro. |
| Environnement SQL | SQL Server Management Studio (SSMS) version 22.10.2+224.12217.157 pour l'administration et le développement T-SQL. |
| Extraction des API | Python pour télécharger les réponses USGS et World Bank et conserver les fichiers bruts ; extraction distincte du traitement. |
| ETL et transformations | SQL Server / T-SQL exclusivement pour les transformations, la normalisation, les contrôles, les rejets et les journaux de chargement. |
| Schémas | Trois schémas séparés dans une même base SQL Server (choix retenu parmi les possibilités du cahier des charges) : `stg` (brut chargé), `ods` (données nettoyées en 3NF) et `dw` (entrepôt en étoile). |
| Nommage | Tables en minuscules ; procédures stockées préfixées par `usp_` ; scripts SQL numérotés, par exemple `01_create_stg.sql` et `02_load_stg.sql`. |
| Versionnement | Git et dépôt de groupe hébergé sur GitHub. Le dépôt de groupe est disponible à l'adresse indiquée sur la page de garde. L'organisation détaillée des dossiers sera précisée lors de la phase d'implémentation. |
| Restitution | Power BI ; cinq pages (quatre métier et une qualité), au moins dix mesures DAX documentées dont un ratio et une comparaison temporelle, segments, info-bulles, drill-down et rôle RLS cohérent avec SQL Server. |

## 6. Références et conditions de réutilisation

Les dates de consultation ci-dessous correspondent à la préparation de cette note (10 novembre 2026). Les licences sont indiquées à partir des pages officielles générales ; les éventuelles conditions particulières attachées à une version ou à un indicateur précis prévalent.

1. **U.S. Geological Survey (USGS).** *FDSN Event Web Service : Earthquake Catalog, documentation et requête.* Documentation : https://earthquake.usgs.gov/fdsnws/event/1/. Requête utilisée pour l'échantillon de travail : https://earthquake.usgs.gov/fdsnws/event/1/query?format=geojson&starttime=2000-01-01&minlatitude=27&maxlatitude=36&minlongitude=-13&maxlongitude=-1&minmagnitude=4. Consulté le 10/11/2026. **Réutilisation :** les informations produites par l'USGS sont généralement dans le domaine public américain ; l'USGS demande de créditer la source. Cette indication ne doit pas être interprétée comme une garantie juridique universelle hors des États-Unis. Crédit proposé : « Données : U.S. Geological Survey (USGS) ». Références officielles : https://www.usgs.gov/faqs/are-usgs-reportspublications-copyrighted et https://www.usgs.gov/information-policies-and-instructions/acknowledging-or-crediting-usgs.

2. **GeoNames.** *GeoNames Export : Morocco (MA.zip)* et documentation du format : https://download.geonames.org/export/dump/MA.zip ; https://www.geonames.org/export/. Consulté le 10/11/2026. **Licence :** Creative Commons Attribution (CC BY 4.0) annoncée par GeoNames pour ses données ; attribution obligatoire, par exemple « GeoNames, https://www.geonames.org/ ». Conditions officielles : https://www.geonames.org/terms.htm et texte de la licence : https://creativecommons.org/licenses/by/4.0/.

3. **Banque mondiale.** *World Development Indicators : Rural population, Morocco (MAR), indicateur SP.RUR.TOTL.* API : https://api.worldbank.org/v2/country/MAR/indicator/SP.RUR.TOTL?format=json&per_page=100. Métadonnées de l'indicateur : https://data.worldbank.org/indicator/SP.RUR.TOTL?locations=MA. Consulté le 10/11/2026. **Licence :** CC BY 4.0 est la licence générale par défaut pour les jeux de données de la Banque mondiale, sauf indication différente dans les métadonnées du jeu ou de l'indicateur. Attribution proposée : « Banque mondiale, World Development Indicators, SP.RUR.TOTL ». Conditions officielles : https://datacatalog.worldbank.org/public-licenses et https://data.worldbank.org/summary-terms-of-use.

4. **Enseignant du cours SGBD.** *Kit pédagogique interne P12 : rapports de terrain et centres d'hébergement*, remis dans l'archive de projet : dix fichiers CSV, le classeur `centres_hebergement.xlsx` et le fichier `LISEZMOI.txt`. Consulté le 10/11/2026. **Licence :** aucune licence ouverte de redistribution n'est mentionnée dans le kit fourni. Les données sont décrites comme simulées à des fins pédagogiques. Usage limité au cadre du cours et au projet ; ne pas republier le kit ou ses données hors de ce cadre sans autorisation de l'enseignant.

5. **Université Euromed de Fès / EIDIA.** *P12 : Cahier des charges et consignes du livrable J1, SGBD / Big Data Analytics, année universitaire 2026–2027*, documents pédagogiques fournis dans l'archive du projet. Consulté le 10/11/2026. **Droits :** document pédagogique fourni pour la réalisation du travail ; aucune licence de redistribution publique n'est indiquée.

**Vérification finale avant dépôt.** Recontrôler la page de conditions de chaque source à la date de remise, conserver une copie ou une capture de ces mentions, et vérifier les métadonnées propres à la version effectivement téléchargée. Pour le kit enseignant et les documents de cours, demander une confirmation écrite si une diffusion publique du dépôt ou des annexes est envisagée.

## A. Annexes

### A.1 Extraits réels du kit pédagogique fourni

Les extraits suivants ont été copiés directement des fichiers contenus dans l'archive `P12_Projet_SGBD_BigData.zip`. Les valeurs et l'orthographe des champs sont conservées telles quelles : aucune correction ou normalisation n'a été appliquée dans ces annexes. Les rapports sont des données simulées, comme le précise le fichier `LISEZMOI.txt` du kit.

**rapport_terrain_Adassil.csv**

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Aguersafen 0,109,98,1,coupée,oui,Nourriture,2023-09-18
Douar Imi 1,19,19,0,praticable,oui,Soins,2023-09-29
```

**rapport_terrain_Amizmiz.csv**

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Tafraout 0,162,69,2,?,oui,Nourriture,13/09/2023
Douar Tafraout 1,83,64,19,?,partiel,Nourriture,2023-09-12
```

**rapport_terrain_Anougal.csv**

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Imi 0,60,31,11,Coupee,partiel,Eau,2023-09-26
Douar Ait 1,98,91,6,praticable,oui,tentes / couvertures,2023-09-13
```

**rapport_terrain_Asni.csv**

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Tafraout 0,110,82,22,coupée,non,Nourriture,23/09/2023
Douar Aguersafen 1,170,169,0,praticable,partiel,Tentes,14/09/2023
```

### rapport_terrain_Ighil.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Ait 0,120,15,40,praticable,non,Nourriture,20/09/2023
Douar Imi 1,179,175,1,praticable,partiel,Tentes,27/09/2023
```

### rapport_terrain_Imi_NTala.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Ait 0,173,160,10,Coupee,oui,Soins,2023-09-13
Douar Imi 1,73,7,58,coupée,non,Soins,2023-09-09
```

### rapport_terrain_Moulay_Brahim.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Tafraout 0,66,26,0,coupée,oui,Nourriture,2023-09-26
Douar Aguersafen 1,63,28,25,coupée,non,Tentes,2023-09-28
```

### rapport_terrain_Ouirgane.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Aguersafen 0,104,25,16,praticable,partiel,Eau,2023-09-14
Douar Aguersafen 1,16,16,0,Coupee,non,Nourriture,10/09/2023
```

### rapport_terrain_Talat_NYaaqoub.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Ait 0,38,5,4,praticable,non,Tentes,2023-09-23
Douar Tafraout 1,74,10,4,coupée,non,Eau,20/09/2023
```

### rapport_terrain_Tizi_NTest.csv

```
douar,menages,maisons_detruites,maisons_endommagees,etat_route,acces,besoin_prioritaire,date_visite
Douar Imi 0,57,53,0,?,non,Tentes,14/09/2023
Douar Imi 1,150,78,27,Coupee,partiel,Eau,2023-09-17
```

**Classeur `centres_hebergement.xlsx` : feuille de données, cinq premières lignes** L'extrait ci-dessous reprend les noms de colonnes et les cinq premières lignes de données du classeur, dans l'ordre d'origine.

```
centre | commune | capacite | personnes_hebergees | gestionnaire
Centre 0 | Imi N'Tala | 329 | 699 | FAR
Centre 1 | Imi N'Tala | 444 | 176 | Commune
Centre 2 | Anougal | 357 | 92 | Croissant-Rouge
Centre 3 | Ighil | 144 | 267 | FAR
Centre 4 | Moulay Brahim | 494 | 84 | Croissant-Rouge
```

## A.2 Extraits des sources externes communiqués pour le projet

Les extraits ci-dessous reproduisent des enregistrements transmis à l'équipe lors du profilage des fichiers bruts. Ils illustrent la structure des réponses ; les fichiers complets restent conservés séparément dans leur format d'origine.

**World Bank : `population_rurale_maroc.json`** L'en-tête indique une réponse paginée contenant 66 observations pour l'indicateur `SP.RUR.TOTL`, correspondant à la population rurale du Maroc. Deux observations réelles sont reproduites ci-dessous :


```
{"page":1,"pages":1,"per_page":100,"total":66,"sourceid":"2","lastupdated":"2026-10-08"}
{"indicator":{"id":"SP.RUR.TOTL","value":"Rural population"},"country":{"id":"MA","value":"Morocco"},"countryiso3
↪  code":"MAR","date":"2025","value":14170247,"unit":"","obs_status":"","decimal":0}
{"indicator":{"id":"SP.RUR.TOTL","value":"Rural population"},"country":{"id":"MA","value":"Morocco"},"countryiso3
↪  code":"MAR","date":"2024","value":14166268,"unit":"","obs_status":"","decimal":0}
```


**GeoNames : `MA.txt`** Le fichier est un texte tabulé sans ligne d'en-tête. Les premières lignes sont des enregistrements géographiques ; l'extrait ci-dessous conserve les champs dans leur ordre d'origine (19 colonnes séparées par des tabulations, représentées ici par « | » pour la lisibilité) :


```
2375946 | Afṭoûṭ Tmeïmîchât | Aftout Tmeimichat | Aftout Temimichate,Aftout Tmeimichat,Aftout Tmeïmichat,Aftoût
↪  Tmeïmîchât,Afṭoûṭ Tmeïmîchât,Akhtout Tmemichat | 21.21497 | -14.4164 | T | DPR | MA | MR | 08 |  |  |  | 0 |
↪  | 187 | Africa/Nouakchott | 2021-08-05
2376131 | Galb Tiquit | Galb Tiquit | Galb Tikite,Galb Tiquit,Galb Tquit,Guelb Tikit,Guelb et Tikit,Guelb et Tîkît
↪  | 22.94562 | -13.05755 | T | HLL | MA |  | 00 |  |  |  | 0 |  | 312 | Africa/Nouakchott | 2021-08-05
2376300 | Teniamum el Jadra | Teniamum el Jadra | Teniamoum al Khadra,Teniamoun es Sadra,Teniamum el
↪  Jadra,Téniamoun es Sadra | 23.31707 | -12.39313 | T | HLL | MA |  | 00 |  |  |  | 0 |  | 287 |
↪  Africa/Nouakchott | 2021-08-05
```


Ces trois lignes sont reproduites à titre d'exemple de structure. Elles ne constituent pas les localités retenues dans la zone d'étude : le filtrage spatial et la sélection des lieux habités seront appliqués lors du traitement. La classe `P` désigne les lieux habités.